

# SKALA

데이터분석 및 AIOps

## 모델개발 및 최적화

2026.07

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.



1. 분석 프로세스 이해
2. 데이터 준비
3. Feature Engineering
4. 모델 학습 및 최적화
5. 모델 평가
6. 모델 해석
7. 모델 모니터링

데이터 분석 및 AIOps

# 1. 분석 프로세스 이해

- 데이터 분석 프로세스
- 시나리오 기반 분석 프로세스 이해

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

# 데이터 분석 프로세스


데이터 분석 과제를 수행하기 위해 실제로 진행하는 단계별 작업 절차





# 시나리오 기반 분석 프로세스 이해

문제 정의부터 분석 모델링까지의 개념적 흐름




# [참고] 분석 기간 종류

관찰 기간, 예측 기간

- 관찰 기간 : Observation Window, Feature를 수집하는 과거 기간, X 변수 생성 기간
- 예측 기간 : Target Window, Target 을 판단하는 미래 구간, Y 변수 생성 기간
- 기준일 : Reference Date, 미래를 예측하는 기준 시점

예시) 고객 이탈 예측 모형



➔ 이탈 예측 모형의 의미

: 과거 3년간의 고객 행동 데이터를 기반으로, 미래 6개월 내 이탈 여부를 예측하는 모델

데이터 분석 및 AIOps

## 2. 데이터 준비


- 데이터 준비 중요도
- 데이터 품질 이슈
- 데이터 처리 용어

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

# 데이터 특성 이해

데이터 특성에 따른 모델 전략이 필요

## 모델 개발 프로세스



# 데이터 특성에 따른 모델 전략

동일한 유형의 문제(예: 예측/분류) 라도 데이터 특성이 다르면 최적 전략도 달라짐


| 데이터 특성     |           | 모델 전략 예시                                                                                                              |
|------------|-----------|-----------------------------------------------------------------------------------------------------------------------|
| Type       | 정형        | <ul style="list-style-type: none"> <li>고정 스키마 (행·열)</li> <li>Feature Engineering + ML</li> </ul>                      |
|            | 비정형       | <ul style="list-style-type: none"> <li>텍스트/ 이미지/ 음성 등</li> <li>대규모 사전학습 모델 +Fine Tuning, DL</li> </ul>                |
| Size       | Small     | <ul style="list-style-type: none"> <li>데이터 증강 전략</li> <li>복잡도가 낮은 모델, 비지도 학습, Rule Based 전략</li> </ul>                |
|            | Big       | <ul style="list-style-type: none"> <li>모델 보다 학습/추론 인프라, 자동화 설계가 중요</li> </ul>                                         |
| Processing | Batch     | <ul style="list-style-type: none"> <li>일정 주기로 대량 데이터 처리 방식, 복잡한 모델과 Feature 사용 가능</li> <li>예시) 일일 상품 추천 모델</li> </ul> |
|            | Real-time | <ul style="list-style-type: none"> <li>모델 정확도 보다 "답변 응답 시간, 운영 안정성"이 더 중요</li> <li>예시) 실시간 상품 추천 모델</li> </ul>        |



# 데이터 준비: 가장 시간이 많이 드는 단계

데이터 준비는 분석 단계 중 노력 측면에서는 가장 많은 시간이 소요됨

## 분석 단계 별 중요도 및 소요 시간 비율



## 모델개발을 위한 데이터 구축 프로세스 예시




# 데이터 품질 점검

Garbage In, Garbage Out

## 데이터 품질 저하에 따른 분석 이슈

### [ 데이터 분석 절차 ]




### [ 데이터 품질 이슈 ]

- 입력 시점에 부정확한 정보 유입
- 부정확한 Data 추출
- 부정확 Data를 수정하는 시간/ 비용 발생
- 부정확한 Data 발견 못하고 분석 실행
- Model 정확도 저하 요인
- Model 결과 왜곡으로 잘못된 의사결정을 유도함

# 데이터 처리 용어

Preparation, Preprocessing, Wrangling

- Data Preparation (데이터 준비): 데이터 처리의 포괄적 개념
- Data Preprocessing (데이터 전처리)
  - 모델 개발을 위한 최소한의 데이터 준비 과정
  - 필요한 경우 한번만 진행됨
  - 예) Data Cleaning, Data Reduction 등
- Data Wrangling (데이터 랭글링)
  - 모델 성능 향상을 위한 반복적인 과정
  - 예) Sampling, Data Partitioning, Data Binning, Scaling, Missing / Outlier 처리 등



그럼 Feature Engineering 이란?

데이터 분석 및 AIOps

# 3. Feature Engineering


- 정의
- Feature Engineering 중요도
- Feature Extraction
- Feature Selection

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

# Feature Engineering 정의

## 정의


- 원본 데이터(Raw Data)를 모델 성능에 도움이 되는 형태(Feature)로 가공하는 모든 과정
- ML / DL 에 사용되는 Feature 를 개발하는 과정으로 시간이 많이 걸리고, 모형 성능에 영향을 크게 줌
- 모델에 도움이 되는 한 어떤 요소도 Feature 가 될 수 있음



# 모델 개발 Pipeline 에서 위치

- 전체 모델 개발 흐름 속에서 Feature Engineering의 위치
- 데이터 전처리는 데이터를 분석 가능한 형태로 변환하는 과정이고, 그 중에서 모델 성능에 초점을 둔 단계가 Feature Engineering 임

## ✓ 모델 개발 Pipeline




# Feature Engineering 중요도

중요도

Feature engineering is an essential parameter of a successful model as observed below:

Parameter Priority.





# Feature Extraction

## Feature Extraction 방법

### Feature Transformation


- 알고리즘 기반 추출, **기계적 추출 방법**
  - 데이터 자체의 통계적·수학적 구조로부터 자동 추출
  - **사람의 해석 없이도 생성 가능한 Feature**
- 예시) Missing 변환/ 표준화/ Min/ Max...

### Feature Creation (파생변수 생성)

- **도메인 지식 기반 추출, 창의력 영역**
  - 업무 이해를 바탕으로 의미있는 Feature 추출 (**파생 변수**)
- 예시) 가입기간(현재일-가입일), 소득 대비 부채 비율(DTI) ...

# Feature Extraction

알고리즘 기반 추출 예시




# [참고] 차원의 저주 (Curse of Dimensionality)

변수 (차원, Feature) 수가 많아 질 경우 생기는 문제

- 차원이 늘어날수록, 제대로 된 학습을 하려면 필요한 데이터가 기하급수적으로 늘어남
- 데이터가 부족한데 차원만 크면 모델은 빈 공간에서도 규칙을 만들게 됨
- 실제 패턴이 아닌 빈 공간의 규칙을 만들면 Train 성능은 좋고, Test 성능은 폭락 → 과적합 (Over-fitting)


예시) 1차원을 4개 공간으로 나눌 경우



- ✓ Feature Selection
- ✓ Dimension Reduction

# Feature Selection


Feature Selection 목적은 모형 학습 시간 단축과, 모형 안정성 확보에 있음



# Feature Selection > Logical Trend 분석

논리성 검증 + 모델 변별력 + 모델 안정성

- Logical Trend 분석은 변수의 영향 방향과 크기가 비즈니스 측면에서 “논리적으로 맞는지”를 검증하는 과정임
- 모델 변별력, 모델 안정성을 같이 판단함
- Robust Model 은 Robust Feature 에 기초함



데이터 분석 및 AIOps

## 4. 모델 학습 및 최적화


- 모델 학습
- 모델 최적화

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

# 모델 학습

# 모델 Lifecycle 구조


모델 개발에서 부터 모델 운영까지의 Flow





# Data Partition 개념

모델 개발을 위해서 Dataset 을 모델 학습 데이터와 모델 평가 데이터로 나누는 것



모델 학습  
위한 데이터

학습에  
반영되지 않는  
데이터

# Data Partition 방법

## Hold Out, Cross Validation


### Hold Out

- Random Split
  - 데이터를 적정 비율로 해서 무작위로 분할  
Ex) Train : Valid : Test = 6 : 2 : 2
- Timeseries Split
  - 시간 순서로 데이터 분할
  - 시계열 데이터 분석 시 사용



### CV (Cross Validation)

- K-fold Cross Validation
  - 데이터를 K 번 나누어 학습·검증을 반복하고, Valid 성능의 평균으로 모델을 검증하는 방법




- \* Test set 평가 방법
- Holdout : Train 학습 모델 그대로 사용 or Train + Valid Set 으로 재학습
- CV : 전체 Train Set 으로 재학습

# Cross Validation > K-Fold

## K-Fold Cross Validation


- 데이터 건수를 동일하게 단순 분할
- Regression 문제에 주로 사용



# Cross Validation > Stratified K-Fold

## Stratified K-Fold Cross Validation

- (용어) Stratified, 계층화된
- Classification 문제에 주로 사용
- 각 클래스의 비율이 균등하게 유지되도록 데이터 분할 → Class Imbalance 데이터셋인 경우 활용




# Sampling 방법 1/2

## Random Sampling vs Partitioned Sampling

### Random Sampling

- Sample 에 포함될 확률을 동일하게 추출


단순 랜덤 추출 (Simple Random Sampling)



- 모집단에서 단순 무작위 방법 의해 표본을 추출

### Partitioned Sampling

- Test Set 은 그대로 두고, Train 에서만 Sampling 할 경우



- 모델 개발은 Sampling 으로 하지만, 모델 평가는 전수 평가를 하고자 할 경우


# Sampling 방법 2/2

## Over Sampling vs Under Sampling

- Target 변수 Class 불균형 (class imbalance) 시

### Over Sampling


- 작은 Size 의 Class 를 큰 Size 의 Class 로 균형을 맞추고자 할 경우



- Positive class 건수가 너무 적은 경우
- 방법
  - Random Over Sampling : 그대로 복제
  - SMOTE (Synthetic Minority Over-sampling Technique) : Positive 와 가까운 이웃에서 새로운 샘플 생성

### Under Sampling

- 큰 Size 의 Class 를 작은 Size 의 Class 로 균형을 맞추고자 할 경우



- Negative class 건수가 너무 많은 경우

\* Positive vs Negative : 관심 대상 Class vs 비관심 대상 Class

예) 이탈 vs 유지, 불량 vs 정상, 사기거래 vs 정상거래

# 모델 최적화

# 모델 최적화 정의

용어의 이해

## 최적화, 最適化, Optimization

- 주어진 조건이나 제약 내에서 **최상의 결과를 얻도록** 과정이나 방법을 조정하거나 개선하는 과정
- 자원, 시간, 비용 등을 최소화 하거나 효율성, 효과성 등을 최대화 하는 것이 주된 목표
- (예) 경제학에서의 자원 배분, 공학에서의 설계 최적화, 물류에서의 경로 최적화 등

## 머신러닝 모델링에서의 최적화

- 모델의 학습 과정에서 **성능 지표를 개선**하기 위해 하이퍼파라미터 조정 등 모델을 조정하여 최상의 성능을 얻는 과정
- 주요 목표 :
  - ❑ **성능 향상**: 모델이 정확하게 예측하고 좋은 성능을 발휘하도록 조정
  - ❑ **일반화 향상**: 새로운 데이터에 대해 잘 작동할 수 있도록 모델 개선
  - ❑ **효율성 증가**: 학습 과정의 속도를 높이고, 계산 자원을 효율적으로 사용



# 모델 최적화 전략

## 대표적인 최적화 전략

| 최적화 전략 |                       | 핵심 목적                                                                       | 최적화 기법                                                                                                                                                        |
|--------|-----------------------|-----------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 데이터 전략 | Training Data Design  | <ul style="list-style-type: none"> <li>모델 학습에 최적화된 데이터셋 구성</li> </ul>       | <ul style="list-style-type: none"> <li>Segmentation, Sampling</li> <li>Data Partition : Hold Out, Cross Validation</li> </ul>                                 |
|        | Feature Engineering   | <ul style="list-style-type: none"> <li>예측에 유용한 Feature 생성 및 변환</li> </ul>   | <ul style="list-style-type: none"> <li>특성 생성 : 파생변수 생성, Lag 변수 등</li> <li>특성 변환 : Missing 대체, Scaling 등</li> <li>특성 선택 : 신뢰성 검증, 변수 중요도, 논리적 판단</li> </ul>    |
| 모델 전략  | Model Selection       | <ul style="list-style-type: none"> <li>문제 및 데이터 특성에 적합한 알고리즘 선정</li> </ul>  | <ul style="list-style-type: none"> <li>통계분석 / ML / DL</li> <li>Regression 계열, Tree 계열 (XGBoost/LightGBM)</li> </ul>                                           |
|        | Hyperparameter Tuning | <ul style="list-style-type: none"> <li>모델 성능을 최적화하는 하이퍼파라미터 탐색</li> </ul>   | <ul style="list-style-type: none"> <li>Grid / Random / Bayesian Search</li> <li>경험 및 사례 기반 탐색</li> </ul>                                                      |
|        | Regularization        | <ul style="list-style-type: none"> <li>과적합 방지 및 일반화 성능 향상</li> </ul>        | <ul style="list-style-type: none"> <li>L1, L2 정규화 (LASSO, Ridge)</li> <li>뉴런 Dropout, 학습 Early Stopping</li> </ul>                                            |
|        | Ensemble              | <ul style="list-style-type: none"> <li>여러 모델을 결합하여 예측 성능과 안정성 향상</li> </ul> | <ul style="list-style-type: none"> <li>Bagging : Random Forest</li> <li>Boosting : XGBoost, LightGBM</li> <li>Stacking : 이질적인 모델 예측값을 메타 모델의 Input</li> </ul> |


# Hyperparameter Tuning 개념

## 용어의 이해

| Parameter                                                                                                                                                                                                                                                                                                                              | Hyper-parameter                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <ul style="list-style-type: none"> <li>모델 내부에서 데이터로부터 학습된 값</li> <li>(예) Linear Regression: 회귀계수, 절편</li> </ul> <pre> from sklearn.linear_model import LinearRegression  model = LinearRegression() model.fit(X_train, y_train)  # The coefficients print('Coefficients: ', model.coef_) print('Intercept: ', model.intercept_) </pre> | <ul style="list-style-type: none"> <li>모델 외부에서 사용자가 직접 셋팅해 주는 값</li> <li>(예) Decision Tree의 최대 깊이</li> </ul> <pre> tree_classifier = DecisionTreeClassifier(max_depth=2) tree_classifier.fit(X,y)  DecisionTreeClassifier(class_weight=None, criterion='gini', max_depth=2, max_features=None, max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, min_samples_leaf=1, min_samples_split=2, min_weight_fraction_leaf=0.0, presort=False, random_state=None, splitter='best') </pre> |
| <ul style="list-style-type: none"> <li>작업자에 의해 조정되지 않음</li> <li>학습 데이터를 통해 자동으로 업데이트 → 모델의 구조를 결정</li> <li>Part of the model</li> </ul>                                                                                                                                                                                                | <ul style="list-style-type: none"> <li>데이터 분석을 통해 얻어지는 값이 아님</li> <li>사용자에 의해 미리 설정, 학습 과정에도 변경되지 않음<br/>→ 학습 알고리즘의 동작 방식을 결정</li> <li>External to the model</li> </ul>                                                                                                                                                                                                                                                                                                                                  |
| <ul style="list-style-type: none"> <li>모델의 최적화 과정을 통해 결정됨</li> </ul>                                                                                                                                                                                                                                                                   | <ul style="list-style-type: none"> <li>알고리즘을 여러 번 수행하면서 최적의 값을 찾아야 함</li> <li>Not best values, But proper values</li> </ul>                                                                                                                                                                                                                                                                                                                                                                              |

# Hyperparameter 자동 최적화 방법

알고리즘 기반의 튜닝 방법




| 항목     | Grid Search                 | Random Search              | Bayesian Search                      |
|--------|-----------------------------|----------------------------|--------------------------------------|
| 탐색 방식  | 정의된 범위 내 <b>모든 조합</b> 전수 조사 | 정의된 범위 내 <b>무작위 조합</b> 샘플링 | 이전 결과로 다음 <b>최적점을 예측</b>             |
| 탐색 효율  | 차원 ↑ 시 비효율적                 | <b>고차원에서 효율적</b>           | <b>가장 효율적, 적은 시도</b> 로 수렴 가능         |
| 최적해 보장 | <b>격자 안에서는 보장</b>           | 보장 안 됨                     | 이론상 좋은 해에 빠르게 근접                     |
| 언제 사용? | 하이퍼파라미터 수가 적을 때             | 하이퍼파라미터 공간이 넓을 때           | 계산 비용이 큰 모델에 효과적 (DL, LGBM, XGBoost) |

# Overfitting 개념

## 모델 과적합


- Overfitting 은 학습 데이터에서는 잘 맞는데, 검증 데이터에서는 그렇지 않은 경우를 의미
- Overfitting 영향 요인 : 데이터 특성 (Train/Test 비유사도), 데이터 건수, Feature 개수, 알고리즘 복잡도 등



# Overfitting 개념

모델 과적합


Q) 모델 A와 B 중 어느 모델이 좋은 모델일까요?



# Overfitting vs Underfitting

과대 적합, 과소 적합

- Overfitting은 학습이 너무 과해서 학습데이터만 잘 맞추는 것
- Underfitting은 학습이 너무 부족해서 학습데이터도 잘 못 맞추는 것



Q) Overfitting 과 Underfitting 중 어떤 것이 더 문제일까요?

# Overfitting 대응방안

## Overfitting vs Underfitting 대응방안

- 데이터 건수, Feature 갯수, 학습 알고리즘 복잡성 선택으로 따라 대응 가능

|         | <u>Overfitting</u>                                                                               | <u>Underfitting</u>                                                                       |
|---------|--------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| Data    | <ul style="list-style-type: none"> <li>데이터 건수 증가</li> <li>Test 와 유사한 Train Set 구성</li> </ul>     | <ul style="list-style-type: none"> <li>데이터 건수 증가</li> </ul>                               |
| Feature | <ul style="list-style-type: none"> <li>불필요한 Feature 제거</li> </ul>                                | <ul style="list-style-type: none"> <li>Feature 추가</li> </ul>                              |
| 학습 알고리즘 | <ul style="list-style-type: none"> <li>알고리즘 Simplify</li> <li>정규화 (Regularization) 수행</li> </ul> | <ul style="list-style-type: none"> <li>알고리즘 Complexify</li> <li>하이퍼파라미터 범위를 늘림</li> </ul> |

# Data Leakage


학습에서 치명적인 함정

- Data Leakage : 모델이 예측 시점에 알 수 없는 정보를 학습에 사용한 경우
- 모델 개발 시에는 정확도가 매우 높게 나오는데 (예: 99%), 실제 데이터를 넣으면 현저히 성능이 저하되는 이유
- Overfitting 은 주로 모델 설계 문제, Data Leakage 는 데이터 설계 문제

## Data Leakage

### Target Leakage

- Feature에 Target 정보가 직접/간접 포함  
예시) 폐렴 환자 예측시 "항생제 처방 여부" 피처 사용,  
고객 이탈 예측시 "해지 위약금 지불 여부" 피처 사용



### Train-Test Contamination

- Test 데이터가 학습 과정에 일부라도 노출된 상태  
예시) 전체 데이터의 평균, 표준편차로 Scaling,  
전체 데이터 평균으로 Missing 대체





# Quiz

1. [Feature Engineering] Missing 대체 작업시 평균값을 산출하는 데이터와, 그 값을 적용하는 데이터의 올바른 관계는?

(산출 대상 Dataset -> 적용 대상 Dataset)

- ① All -> Train / Validation / Test
- ② Train -> Train / Validation / Test
- ③ Train + Validation -> Train / Validation / Test
- ④ Train -> Train, Validation -> Validation, Test -> Test
- ⑤ 과제에 따라 다름

2. [모델 튜닝] Hyperparameter Tuning 을 통해서 모델 성능을 최대로 올리고자 함. 어떤 데이터셋의 성능을 기준으로 하이퍼파라미터를 최적화해야 하는가?

- ① Train ② Validation ③ Test ④ Train, Validation 평균값 ⑤ Validation, Test 평균값

3. [모델 평가] “암 예측 모델의 정확도는 95% 이다” 라고 할 때 그 정확도 산출 대상이 되는 데이터 셋은?

- ① Train ② Validation ③ Test ④ Validation, Test 평균값 ⑤ 상황에 따라 다름

데이터 분석 및 AIOps

## 5. 모델 평가

- 모델 평가 지표 종류
- Classification 모델 평가 지표
- Regression 모델 평가 지표

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

# 모델 평가 지표 종류

모델 평가 지표는 문제 유형, 비즈니스 목적에 따라 선택해야 함

| 문제 유형                  | Output 유형         | 평가 지표 (Metrics)                                                                                                              |
|------------------------|-------------------|------------------------------------------------------------------------------------------------------------------------------|
| 분류<br>(Classification) | Class (1, 0)      | <ul style="list-style-type: none"> <li>Confusion Matrix (Accuracy / Precision / Recall / F1 Score)</li> </ul>                |
|                        | Probability (0~1) | <ul style="list-style-type: none"> <li>AUC / LIFT / AUCPR / K-S</li> </ul>                                                   |
| 회귀<br>(Regression)     | 실수값               | <ul style="list-style-type: none"> <li>Mean Absolute Error : <math>\sum  예측값 - 실제값  / n</math></li> </ul>                    |
|                        |                   | <ul style="list-style-type: none"> <li>Mean Squared Error : <math>\sum (예측값 - 실제값)^2 / n</math></li> </ul>                   |
|                        |                   | <ul style="list-style-type: none"> <li>Root Mean Squared Error : <math>\text{Root}(\sum (예측값 - 실제값)^2 / n)</math></li> </ul> |
|                        |                   | <ul style="list-style-type: none"> <li>Mean Absolute Percentage Error : <math>\sum ( 예측값 - 실제값  / 실제값) / n</math></li> </ul> |
|                        |                   | <ul style="list-style-type: none"> <li>R-Square : <math>1 - (\sum (실측값 - 예측값) / \sum (실측값 - 평균값)^2)</math></li> </ul>        |

# Classification 모델 평가 지표

# Confusion Matrix

Confusion Matrix 는 실제 분류값과 예측 분류값의 비교 분류표를 뜻함

| Confusion Matrix |          | Actual   |          |
|------------------|----------|----------|----------|
|                  |          | Positive | Negative |
| Predict          | Positive | TP       | FP       |
|                  | Negative | FN       | TN       |

- Positive vs Negative  
: 관심 대상 Class vs 비관심 대상 Class  
예) 이탈 vs 유지, 불량 vs 정상, 사기거래 vs 정상거래
- **TP**: True Positive, 실제 Positive를 Positive로 맞게 예측
- **TN**: True Negative, 실제 Negative를 Negative로 맞게 예측
- **FP**: False Positive, 실제 Negative를 Positive로 잘못 예측
- **FN**: False Negative, 실제 Positive를 Negative로 잘못 예측

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

: 전체 중에서 얼마나 맞췄는가?

$$Recall = \frac{TP}{TP + FN}$$

: 실제 Positive 중에서 얼마나 잡아냈는가?

$$Precision = \frac{TP}{TP + FP}$$

: Positive 라고 예측 한 것 중에서 얼마나 진짜인가?

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

: Recall과 Precision의 균형 수준은 어떠한가?


# Confusion Matrix

Confusion Matrix 는 실제 분류값과 예측 분류값의 비교 분류표를 뜻함

Confusion Matrix (오분류표)

|        | 예측값    |        | Total: 100 |
|--------|--------|--------|------------|
| 실제값    | 1 (이탈) | 0 (유지) |            |
| 1 (이탈) | 20     | 5      | 이탈 : 25    |
| 0 (유지) | 15     | 60     | 유지 : 75    |

| 평가 지표 (Metric)    | 정의                                                   | 예시                                       |
|-------------------|------------------------------------------------------|------------------------------------------|
| • Accuracy (정확도)  | 전체 중에 올바르게 예측한 비율                                    | $(20 + 60) / 100 = 0.80$                 |
| • Recall (재현율)    | 실제 1 중에 예측 1의 비율                                     | $20 / (20 + 5) = 0.80$                   |
| • Precision (정밀도) | 예측 1 중에 실제 1의 비율                                     | $20 / (20 + 15) = 0.57$                  |
| • F1 Score        | Precision 과 Recall 의 조화평균<br>$(2 * P * R) / (P + R)$ | $2 * 0.57 * 0.80 / (0.57 + 0.80) = 0.67$ |



# Confusion Matrix

## (Quiz)

1. 아래는 CCTV를 이용한 범인 색출 모형입니다. 모델 중 가장 성능이 좋은 모델은?
2. 일반인을 범인으로 오탐지하는 오류를 최소화하려고 할때 어떤 모델을 선택해야 하는지?

모델 A) Total : 100

|        | 예측값    |        |
|--------|--------|--------|
| 실제값    | 1 (범인) | 0 (일반) |
| 1 (범인) | 8      | 2      |
| 0 (일반) | 27     | 63     |

- Accuracy : 0.71
- Recall : 0.80
- Precision : 0.23
- F1 Score : 0.36

모델 B) Total : 100

|        | 예측값    |        |
|--------|--------|--------|
| 실제값    | 1 (범인) | 0 (일반) |
| 1 (범인) | 5      | 5      |
| 0 (일반) | 15     | 75     |

- Accuracy : 0.80
- Recall : 0.50
- Precision : 0.25
- F1 Score : 0.33

모델 C) Total : 100

|        | 예측값    |        |
|--------|--------|--------|
| 실제값    | 1 (범인) | 0 (일반) |
| 1 (범인) | 0      | 10     |
| 0 (일반) | 0      | 90     |

- Accuracy : 0.90
- Recall : 0.00
- Precision : N/A
- F1 Score : N/A

# [참고] Baseline 모델 vs Navie 모델

성능 비교 위한 기준 모델

- 모델 성능 평가는 평가지표 절대값보다 “비교 기준”이 더 중요

|             |                                                                                                                                                                                                                                                                                                                                     |
|-------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Baseline 모델 | <ul style="list-style-type: none"> <li>• 모델 성능 평가시 비교 대상으로 사용하는 모델</li> <li>• 예시)             <ul style="list-style-type: none"> <li>- 이전에 개발한 모델</li> <li>- 가장 단순한 ML 모델, 예) 선형 Regression 모델</li> <li>- 규칙기반 Rule 모델</li> <li>- Navie 모델</li> </ul> </li> </ul>                                                                   |
| Navie 모델    | <ul style="list-style-type: none"> <li>• 학습 없이 가장 단순한 규칙만으로 예측하는 모델</li> <li>• 예시)             <ul style="list-style-type: none"> <li>- 분류 모델 : Y 변수의 다수 클래스(Majority Class) 로 예측<br/>예) 불량 5%, 정상 95% → 전부 “정상” 예측</li> <li>- 회귀 모델 : Y 변수의 평균값(mean) 으로 예측, (시계열) 직전 값으로 예측<br/>예) 내일 주가 예측 시 “전일 종가” 로 예측</li> </ul> </li> </ul> |



# AUC (AUROC, ROC-AUC)


분류 임계값(threshold)을 0부터 1까지 변화시키면서 모델의 성능을 종합적으로 평가하는 지표

- AUC = ROC Curve 아래의 면적(Area Under the ROC Curve)
- ROC 곡선 : 분류 임계값을 0에서 1까지 변화시킬 때 모델의 예측 성능 변화를 나타낸 그래프

예시) 예측 Score 기준 내림차순 정렬된 데이터

| No | 실제 Class | 예측 Score | 누적 전체 구성비 | 누적 1 구성비 | 누적 0 구성비 |
|----|----------|----------|-----------|----------|----------|
| 1  | 1        | 0.90     | 0.05      | 0.10     | 0.00     |
| 2  | 1        | 0.80     | 0.10      | 0.20     | 0.00     |
| 3  | 0        | 0.70     | 0.15      | 0.20     | 0.10     |
| 4  | 1        | 0.60     | 0.20      | 0.30     | 0.10     |
| 5  | 1        | 0.55     | 0.25      | 0.40     | 0.10     |
| 6  | 1        | 0.54     | 0.30      | 0.50     | 0.10     |
| 7  | 0        | 0.53     | 0.35      | 0.50     | 0.20     |
| 8  | 0        | 0.52     | 0.40      | 0.50     | 0.30     |
| 9  | 1        | 0.51     | 0.45      | 0.60     | 0.30     |
| 10 | 0        | 0.51     | 0.50      | 0.60     | 0.40     |
| 11 | 1        | 0.40     | 0.55      | 0.70     | 0.40     |
| 12 | 0        | 0.39     | 0.60      | 0.70     | 0.50     |
| 13 | 1        | 0.38     | 0.65      | 0.80     | 0.50     |
| 14 | 0        | 0.37     | 0.70      | 0.80     | 0.60     |
| 15 | 0        | 0.36     | 0.75      | 0.80     | 0.70     |
| 16 | 0        | 0.35     | 0.80      | 0.80     | 0.80     |
| 17 | 1        | 0.34     | 0.85      | 0.90     | 0.80     |
| 18 | 0        | 0.33     | 0.90      | 0.90     | 0.90     |
| 19 | 1        | 0.30     | 0.95      | 1.00     | 0.90     |
| 20 | 0        | 0.10     | 1.00      | 1.00     | 1.00     |

누적 1 구성비  
(Sensitivity)



| AUC             |        |      |          |      |           |         |
|-----------------|--------|------|----------|------|-----------|---------|
| < 0.5           | 0.5    | 0.6  | 0.7      | 0.8  | 0.9       | 1.0     |
| Something Wrong | Random | Poor | Mediocre | Good | Excellent | Perfect |

# LIFT

전체 집단에 비해 특정 집단의 예측력이 향상된 정도

- 직관적인 평가지표로, 예측 Score 상위 고객을 선별하여 업무에 활용할 때 유용
- Lift : 상위 K건의 Positive 비율이 무작위 대비 몇 배인지 나타내는 지표

Score Data

| No  | 실제 Class | 예측 Score |
|-----|----------|----------|
| 1   | 0        | 0.90     |
| 2   | 1        | 0.80     |
| 3   | 0        | 0.70     |
| 4   | 1        | 0.60     |
| 5   | 0        | 0.55     |
| 6   | 1        | 0.54     |
| 7   | 0        | 0.53     |
| 8   | 1        | 0.52     |
| 9   | 1        | 0.51     |
| 10  | 0        | 0.51     |
| ~   | ~        | ~        |
| 100 | 0        | 0.11     |




LIFT Table

| 누적 구성비 | 누적 전체 Count (a) | 누적 1 Count (b) | b/a  | LIFT |
|--------|-----------------|----------------|------|------|
| 10%    | 10              | 5              | 0.50 | 3.33 |
| 20%    | 20              | 6              | 0.30 | 2.00 |
| 30%    | 30              | 7              | 0.23 | 1.56 |
| 40%    | 40              | 9              | 0.23 | 1.50 |
| 50%    | 50              | 11             | 0.22 | 1.47 |
| 60%    | 60              | 13             | 0.22 | 1.44 |
| 70%    | 70              | 15             | 0.21 | 1.43 |
| 80%    | 80              | 15             | 0.19 | 1.25 |
| 90%    | 90              | 15             | 0.17 | 1.11 |
| 100%   | 100             | 15             | 0.15 | 1.00 |

\* Lift = (상위 K% 구간의 Positive Rate(=b/a))  
/ (전체 데이터의 Positive Rate(=0.15))

Total : 100건  
Positive(=1) : 15건, 비율 : 0.15

LIFT Chart



" Score 상위 10% 추출시 무작위 추출에 비해 약 3.33배 높은 수의 이탈 고객들을 예측 할 수 있음 "

# AUC & LIFT

## AUC & LIFT 해석

- AUC 로 전체 집단의 모형 성능을 평가하고, LIFT 로 관심 집단의 성능을 평가

(AUC & LIFT 해석 예시)

| 모델 구분 | AUC  | LIFT |     |     |     |     | 평가 및 해석                          |
|-------|------|------|-----|-----|-----|-----|----------------------------------|
|       |      | 1%   | 10% | 20% | 30% | 50% |                                  |
| 모델 A  | 0.95 | 4.6  | 3.5 | 2.8 | 2.2 | 1.7 | 전반적인 성능 Excellent                |
| 모델 B  | 0.94 | 4.5  | 4.1 | 3.5 | 2.3 | 1.6 | 전반적인 성능 Excellent , 10% 에서 최고 성능 |
| 모델 C  | 0.88 | 6.3  | 3.9 | 2.7 | 2.0 | 1.5 | 전반적인 성능 Good, 1% 에서 최고 성능        |
| 모델 D  | 0.61 | 2.3  | 2.5 | 2.1 | 1.7 | 1.3 | 전반적인 성능 Poor, 그러나 20% 까지 2배 성능   |

\* 참고) AUC : Excellent = 0.9~1, Good = 0.8~0.9, Mediocre = 0.7~0.8, Poor = 0.6~0.7, Random = 0.5~0.6

# 분류 평가지표 특징 비교

비즈니스 상황에 맞는 지표 선정

- 일반적으로 많이 사용되는 평가 지표는 Accuracy, F1, AUC
- 특정 목적에서 주로 사용되는 평가지표는 Precision, Recall, LIFT

|           | 특징                                                                                                         | 평가 사례 예시                                                                                                |
|-----------|------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------|
| Accuracy  | <ul style="list-style-type: none"> <li>• 특정 Threshold 下 에서 Both Classes (0, 1) 를 평가, Class 균등</li> </ul>   | <ul style="list-style-type: none"> <li>• 성별, 개/고양이</li> </ul>                                           |
| F1        | <ul style="list-style-type: none"> <li>• 특정 Threshold 下 에서 Positive Class (1) 의 오탐 / 미탐 모두 평가</li> </ul>   | <ul style="list-style-type: none"> <li>• 금융사기, 암환자</li> </ul>                                           |
| Precision | <ul style="list-style-type: none"> <li>• 특정 Threshold 下 에서 Positive Class (1) 의 예측값 적중율(오탐) 평가</li> </ul>  | <ul style="list-style-type: none"> <li>• 스팸 메일 (정상 메일을 스팸으로 분류하면 심각한 문제, 스팸을 놓치는 건 비교적 덜 위험)</li> </ul> |
| Recall    | <ul style="list-style-type: none"> <li>• 특정 Threshold 下 에서 Positive Class (1) 의 실제값 탐지율(미탐) 평가</li> </ul>  | <ul style="list-style-type: none"> <li>• 암 환자 (암환자를 놓치면 생명 위험, 오탐은 추가 검사로 해결 가능)</li> </ul>             |
| AUC       | <ul style="list-style-type: none"> <li>• Class 분류 없이 전체 Probability 에서 Both Classes (0, 1) 를 평가</li> </ul> | <ul style="list-style-type: none"> <li>• 신용평가</li> </ul>                                                |
| LIFT      | <ul style="list-style-type: none"> <li>• Class 분류 없이 상위 Probability 에서 Positive Class (1) 를 평가</li> </ul>  | <ul style="list-style-type: none"> <li>• 마케팅 타겟 추천</li> </ul>                                           |

# Regression 모델 평가 지표

# 회귀모형 성능 평가


회귀모형의 성능은 오차의 크기 또는 모델의 설명력 관점에서 평가됨

- 오차 크기 : 모델이 얼마나 정확하게 예측하는지를 평가
- 모델 설명력 : 모델이 데이터를 얼마나 잘 설명하는지를 평가

| 평가 척도   |                     |                                            | 수식                                                                              | 해석                        |
|---------|---------------------|--------------------------------------------|---------------------------------------------------------------------------------|---------------------------|
| 오차의 크기  | MAPE                | Mean Absolute Percentage Error (평균절대백분율오차) | ✓ 오차의 절대값을 실제값으로 나눈 후 모두 더한 다음 데이터 크기로 나눈 값<br>→ $\sum ( 실제값 - 예측값  / 실제값) / n$ | 0에 가까울수록<br>예측 오차가 적은 모델임 |
|         | MAE                 | Mean Absolute Error (평균절대오차)               | ✓ 오차의 절대값을 모두 더한 다음 데이터 크기로 나눈 값<br>→ $\sum  실제값 - 예측값  / n$                    |                           |
|         | MSE                 | Mean Squared Error (평균제곱오차)                | ✓ 오차의 제곱을 모두 더한 다음 데이터의 크기로 나눈 값<br>→ $\sum (실제값 - 예측값)^2 / n$                  |                           |
|         | RMSE                | Root Mean Squared Error (평균제곱근오차)          | ✓ 오차의 제곱을 모두 더한 다음 데이터의 크기로 나눈 값의 제곱근<br>→ $\sqrt{\sum (실제값 - 예측값)^2 / n}$      |                           |
| 모델의 설명력 | R <sup>2</sup>      | R-Squared (결정계수)                           | ✓ $SSR / SST = \text{회귀제곱합} / \text{총제곱합}$                                      | 1에 가까울수록<br>설명력이 좋은 모델임   |
|         | Adj. R <sup>2</sup> | Adjusted R-Squared (조정된 결정계수)              | ✓ 독립변수가 여러 개일 때 결정계수에 독립변수의 개수와 데이터 크기를 반영한 값                                   |                           |

# [Review] 회귀모형 개념


회귀모형은 설명변수와 종속변수의 관계를 가장 잘 설명하는 회귀식을 찾는 분석 기법



- 잔차 : 관측값과 예측값의 차이 \* 오차 : 모집단에서의 차이
- 회귀선 : 잔차<sup>2</sup>의 합이 최소가 되는 하나의 직선 (최소제곱법)
 
$$\sum \text{잔차}^2 = \sum (\text{관측값} - \text{예측값})^2 \rightarrow \text{MIN}$$
- 회귀식 : 회귀선을 함수식으로 나타낸 것  
독립변수와 종속변수의 관계를 나타냄
 
$$y = a_1 \cdot x_1 + a_2 \cdot x_2 + \dots + a_n \cdot x_n + b$$
 종속변수(y) = 회귀계수( $a_n$ ) × 독립변수( $x_n$ ) + 상수(b)
- 회귀 분석 : 회귀식을 찾는 분석기법

# 회귀모형 성능 평가 (MAPE)

- MAPE 는 오차의 절대값을 실제값으로 나눈 후 모두 더한 다음 데이터 크기로 나눈 값



$$\text{MAPE} = \sum (|\text{실제값} - \text{예측값}| / \text{실제값}) / n$$

| Test Data            | x   | y                       |             | ABS(관측값 - 예측값) / 관측값         |
|----------------------|-----|-------------------------|-------------|------------------------------|
|                      | 관측값 | 관측값                     | 예측값 (y = x) |                              |
| D                    | 1   | 1                       | 1           | $\text{ABS}(1-1)/1 = 0$      |
| E                    | 1.5 | 2                       | 1.5         | $\text{ABS}(2-1.5)/2 = 0.25$ |
| F                    | 2.5 | 3                       | 2.5         | $\text{ABS}(3-2.5)/3 = 0.17$ |
| MAPE<br>(평균절대백분율 오차) |     | $(0 + 0.25 + 0.17) / 3$ |             |                              |
|                      |     | 0.14                    |             |                              |



# 회귀모형 성능 평가 (MAPE)

## MAPE 해석 시 주의사항 (한계점)

- 0값 문제 : 실제값( $A_i$ )이 "0"일 때 MAPE를 계산할 수 없음
- 데이터 값이 매우 작을 때 상대적으로 큰 오차를 발생시킴 → 과민반응
- MAPE가 무한대로 발산할 때

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{A_i - F_i}{A_i} \right|$$


## (대체) sMAPE, Symmetric MAPE

: 실제값과 예측값의 차이를 두 값을 평균으로 나누어 대칭적인 오차 계산

$$sMAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{A_i - F_i}{\frac{|A_i| + |F_i|}{2}} \right|$$

# 회귀모형 성능 평가 (MAE)

- MAE 는 오차의 절대값을 모두 더한 다음 데이터 크기로 나눈 값




$$MAE = \sum |실제값 - 예측값| / n$$

| Test Data    | x   | y               |             | ABS(관측값 - 예측값) / 관측값 |
|--------------|-----|-----------------|-------------|----------------------|
|              | 관측값 | 관측값             | 예측값 (y = x) |                      |
| D            | 1   | 1               | 1           | ABS(1-1) = 0         |
| E            | 1.5 | 2               | 1.5         | ABS(2-1.5) = 0.5     |
| F            | 2.5 | 3               | 2.5         | ABS(3-2.5) = 0.5     |
| MAE (평균절대오차) |     | (0+0.5+0.5) / 3 |             |                      |
|              |     | 0.33            |             |                      |

# [Review] 회귀모형 성능 평가 ( $R^2$ )

- 결정계수( $R^2$ )는 회귀모델에서 독립변수가 종속변수를 얼마만큼 설명해 주는지를 가리키는 지표
- 지표 해석 : 1에 가까울 수록 성능이 좋고, 음수값이 나오면 Y 평균값으로 예측한 것 (Naïve 모델) 보다 못한 것임



$$SST(\text{총변동}) = SSR(\text{회귀변동}) + SSE(\text{잔차변동})$$

- SST(총편차, 총변동, 제곱합)  
= 관측값 - 평균값 =  $y_i - \bar{y}$
- SSR(설명되는 편차, 회귀변동, 회귀제곱합)  
= 예측값 - 평균값 =  $\hat{y} - \bar{y} = (a \cdot x + b) - \bar{y}$
- SSE(설명 안 되는 편차, 잔차변동, 잔차제곱합)  
= 관측값 - 예측값 =  $y_i - \hat{y} = y_i - (a \cdot x + b)$
- 결정계수( $R^2$ )  
➤  $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$
- 조정된 결정계수( $R^2_{adj}$ )  
 $R^2_{adj} = 1 - \frac{SSE/(n-k-1)}{SST/(n-1)}$ , n: 데이터수, k: 독립변수 수

# 회귀모형 평가지표 특징 비교

데이터 특성과 목적에 따라 선정

| 평가지표 (Metrics) |          | 장점                                                                                                        | 단점                                                                                                    |
|----------------|----------|-----------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------|
| 예측 오차 크기       | MAE      | <ul style="list-style-type: none"> <li>매우 직관적 (평균적인 오차 값)</li> <li>MAE 값이 실제값과 단위가 동일</li> </ul>          | <ul style="list-style-type: none"> <li>데이터 단위(scale)에 의존적</li> </ul>                                  |
|                | MSE      | <ul style="list-style-type: none"> <li>오차 특이값에 Penalty 줌</li> </ul>                                       | <ul style="list-style-type: none"> <li>이상치(outlier)에 매우 민감</li> <li>단위가 제곱이라 해석이 직관적이지 않음</li> </ul>  |
|                | RMSE     | <ul style="list-style-type: none"> <li>오차 특이값에 Penalty 주나, MSE 보다는 완화</li> <li>직관적 (평균적인 오차 값)</li> </ul> | <ul style="list-style-type: none"> <li>이상치(outlier)에 민감</li> <li>데이터 단위(scale)에 의존적</li> </ul>        |
| 비율 오차          | MAPE     | <ul style="list-style-type: none"> <li>직관적 (평균적인 오차 비율)</li> <li>서로 다른 스케일 비교 가능</li> </ul>               | <ul style="list-style-type: none"> <li>실제값이 '0' 인 경우 산출 불가<br/>-&gt; '0' 인 경우는 제외하거나 대체 산출</li> </ul> |
| 설명력            | R-Square | <ul style="list-style-type: none"> <li>모델 설명력 제공 (모형 적합도 의미)</li> <li>일반적으로 0~1 범위로 해석 용이</li> </ul>      | <ul style="list-style-type: none"> <li>'예측력'보다는 '설명력'에 치중</li> </ul>                                  |

데이터 분석 및 AIOps

## 6. 모델 해석

- 모델 해석이 중요한 이유
- SHAP

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

# 모델 해석이 중요한 이유

~~~

## 왜 모델 해석이 중요한가?

### ML/DL 모델 : 블랙박스 모델

머신러닝과 딥러닝 모델은 높은 성능을 제공하지만, 내부 동작을 이해하기 어려운 '블랙박스(Black Box)' 성격을 가짐

통계적 모델 (Linear Regression)

$$y = 0.5 * \text{Age} + 1.2 * \text{Income}$$

→ 계수(Coefficient)를 통해 **인과관계 설명 가능**

## The Solution: XAI

**Explainable AI (XAI)** 기술을 통해 블랙박스 모델을 해석할 수 있음.

그 중 SHAP은 가장 강력하고 이론적으로 검증된 도구임

**SHAP** SHapley Additive exPlanations

각 특성(Feature)이 예측 결과에 기여한 정도를 게임 이론으로 계산

Force Plot 예시




- 신용평가 모델에서 특정 개인의 신용평가 결과에 대해서 각 변수들이 어떻게 영향을 주었는지를 설명해 줌

예시) Age, Income 은 신용평가에 (+) 요인으로 작용하고,

Debt, Loan 은 (-) 요인으로 작용함


# SHAP

## Feature Importance, Feature Impact



- 변수의 평균적인 영향력을 보여주는 것으로, 각 특성이 모델에 미치는 절대 영향도(=기여분)를 파악할 수 있음

예시) 은행 이탈에 가장 중요한 Feature 는 'Age' 임



- 변수의 영향도와 각 변수가 모델에 영향을 주는 분포를 확인함


예시) 은행 이탈에 가장 중요한 Feature 는 'Age' 이고, Age 값이 클수록 이탈에 (+) 요인으로 작용함

# SHAP


## Feature Dependence

- 각 특성별 Target과의 관계 패턴을 보여주는 것으로, 특성간 상호작용도 확인할 수 있음

### Feature Dependence



예시) 'Age' 가 클 수록 이탈율이 증가하고, 같은 연령에서는 'IsActiveMember' =1 일 경우 이탈이 감소함



예시) 'NumOfProducts' 가 많을 수록 이탈율이 높은 패턴을 보임



데이터 분석 및 AIOps

## 7. 모델 모니터링

- Model Drift 란?
- Data Drift / Prediction Drift / Concept Drift
- Model Drift 대응 전략
- Model Renewal 방안

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

# Model Drift란?

모델 개발시점과 운영시점의 모델 성능 차이

## Model Drift 정의

"학습 환경과 운영 환경의 차이로 시간이 지남에 따라 모델의 성능이 저하되는 현상"

## 왜 모니터링해야 하는가?




**성능 하락**  
예측 정확도 및 신뢰도 감소



**잘못된 의사결정**  
오류가 있는 예측 기반의 판단



**비즈니스 손실**  
매출 감소 및 리스크 증가



" 각 유형은 발생하는 원인과 감지 방법이 서로 다름 "

# Data Drift: 입력 분포의 변화

## Definition

모델에 입력되는 데이터의 통계적 분포가 학습 시점과 비교하여 유의미하게 달라지는 현상

Mathematical:  $P_t(X)$  (현재시점)  $\neq P_{ref}(X)$  (기준시점)

## 발생 원인 및 예시



### 사용자/환경 변화

코로나19로 인한 소비 패턴 변화, 새로운 유저 그룹 유입  
(예: 10대 유저 급증)



### 계절성 및 트렌드

주말/공휴일 트래픽 패턴, 특정 시즌 상품 수요 급증




### 데이터 파이프라인 이슈

센서 교체로 인한 단위 변경( $^{\circ}\text{F} \rightarrow ^{\circ}\text{C}$ ), 결측치 처리 로직 변경

## Feature Distribution Comparison

Left : Reference (Train)

Right : Current (Prod)



운영 데이터(파란색)가 훈련 데이터(회색)보다 고연령층으로 이동(Shift)

# Prediction Drift: 예측 분포의 변화

## Definition

모델이 출력하는 예측값(Prediction)의 통계적 분포가 기준 시점과 비교하여 유의미하게 달라지는 현상

Mathematical:  $P_t(\hat{y}) \neq P_{ref}(\hat{y})$

## 특징 및 시사점



### 결과론적 지표 (Downstream Effect)

Data Drift나 Concept Drift가 발생했을 때, 그 결과로서 예측 분포가 변하는 경우가 많음



### 주요 예시

스팸 탐지율 급증(5% → 20%)


긍정/부정 예측 비율 역전

신용점수 예측치가 전반적으로 하락

## Prediction Probability Distribution

Left : Reference (Train)

Right : Current (Prod)



초기(회색)에는 0과 1 양극단에 확신을 가진 예측이 많았으나, 현재(초록색)는 중간 구간(0.4~0.6)의 비중이 높아져 모델의 불확실성이 증가

# Concept Drift: 입력-Target 관계의 변화

## Definition

입력 데이터와 정답(Target) 간의 상관관계(패턴)가 변해서, 기존 모델이 더 이상 유효하지 않게 되는 현상

Mathematical:  $P_t(Y|X) \neq P_{ref}(Y|X)$

## 주요 발생 원인 (Real-world Causes) 예시



### 거시 환경 변화 (Macro Environment)

금리 인상, 법/규제 개정으로 인한 부도 위험 기준 변화



### 비즈니스 프로세스 변경

앱 UI 개편으로 인한 클릭 패턴 변화, 상품 분류 기준 변경




### 주요 애시

경쟁사 등장으로 이탈 요인 변경

경기 침체로 인한 소비 패턴 변화

## Model Performance Decay



“ 모델의 정확도(Accuracy)가 시간이 지남에 따라 점진적으로 하락 ”

# Model Drift 대응 전략

Drift 유형에 맞는 적절한 조치가 필요



## Data Drift

입력 데이터 변화

Formula :

$$Pt(X) \neq Pref(X)$$

입력 피처의 분포  $P(X)$

대응 전략 :

Feature 변경없이 가중치만 조정  
(Re-training)



## Prediction Drift

예측 분포 변화

Formula :

$$Pt(\hat{y}) \neq Pref(\hat{y})$$

모델 예측값의 분포  $P(\hat{y})$

대응 전략 :

의사결정 위한 예측 확률 기준값 조정  
(Threshold Adjustment)



## Concept Drift

관계의 변화

Formula :

$$Pt(Y|X) \neq Pref(Y|X)$$

입력과 정답의 관계  $P(Y|X)$

대응 전략 :

EDA 부터 Feature 생성 등  
모델 재구축  
(Re-modeling)

(대응 절차) 1. 모델 성능 변화없이 예측 분포만 변화 : Threshold Adjustment

2. 모델 성능 변화가 발생 : Re-training -> 개선 없으면 -> Re-modeling

# Model Renewal 방안

모델 변경 수준에 따라 결정

## Renewal 방법

Threshold Adjustment  
(Cut-Off 변경)

등급 or Targeting 구간의 Threshold 조정  
- 예) 기존 신용 1등급은 연체 확률 0.2 이하  
-> 변경 후는 연체 확률 0.15 이하

Re-training  
(모델 재 학습)

Feature 변경 없이 모델만 재학습 실행




- Feature 사용은 동일하나 기존 모델에 사용된 Feature 계수를 변경  
(예, Feature A 계수 0.5 → 0.7로 변경)

Re-modeling  
(모델 재 구축)

Feature 변경 포함하여 모델을 재 생성

- 모델을 완전히 변경하는 것으로서 모델 생성에 필요한 절차를 수행

● 변경 有  
○ 변경 無



데이터 분석 및 AIOps

# Appendix


- End-to-End 모델링 프로세스
- AutoML

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.



# End-to-End 모델링 프로세스

# End-to-End 모델링 프로세스




# AutoML


# AutoML 정의

분석 자동화 (AutoML) 는 분석 Workflow의 전체 또는 일부를 자동화하는 기술임

## Traditional Machine Learning Workflow




## AutoML Workflow




## Machine Learning 장벽

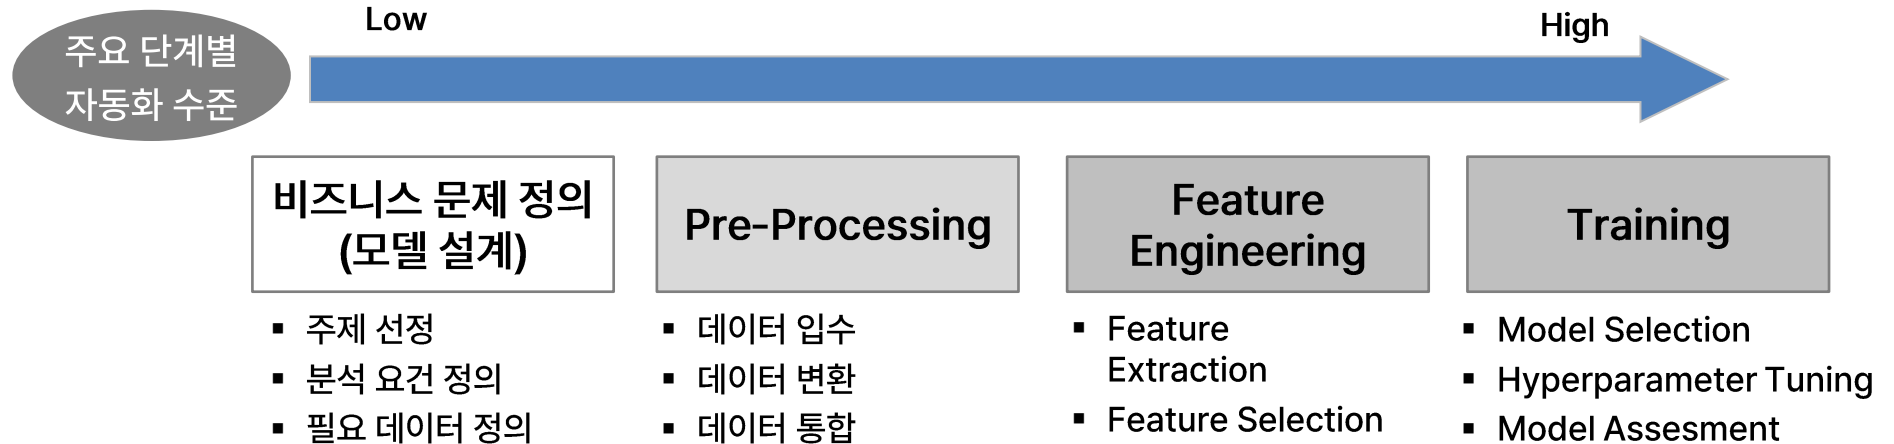
어렵다.



노력이 많이 든다.




## AutoML 자동화 수준



# AutoML 목표

분석 자동화 (AutoML) 의 궁극적인 목표는 Model Life Cycle 자동화에 있음


- 미래 분석 기술은 기계가 스스로 모델을 개발, 모니터링, Re-Modeling 단계로 발전 예상



# Data Analyst 역할 변화

분석 기술 자동화 추세에 따라 분석 전문가의 역할 변화도 예상

- 분석가는 비즈니스, IT 와의 협업 역할이 더욱 강조되는 방향으로 변화
- Data Analyst 층이 넓어지고, 기업에서 역할 증대가 예상됨







**수고하셨습니다.**

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.